




UNIVERSITE DE DOUALA

\*\*\*\*\*

**ECOLE NORMALE SUPERIEURE  
D'ENSEIGNEMENT TECHNIQUE**



B.P. 1872 Douala - Cameroun Tél. : 691.14.25.44 E-mail : ensetdsfc@gmail.com

## DEPARTEMENT DES ENSEIGNEMENTS SCIENTIFIQUES DE BASES

EC.

**ANALYSE DES DONNEES ET STATISTIQUE INFERENTILLE**

*CLASSES :*

*4<sup>ème</sup> Année industrielle*

*ENSEIGNANT*

**TCHASSEM David**

**Chargé de cours**

Année académique 2019-2020

## OBJECTIFS GENERAUX

# PREMIERE PARTIE : STATISTIQUE INFERENTIELLE

## SOMMAIRE PREMIERE PARTIE

|                                                                  |    |
|------------------------------------------------------------------|----|
| Chapitre I ECHANTILLONNAGE.....                                  | 3  |
| A. Le problème de l'échantillonnage.....                         | 3  |
| B. Distribution d'échantillonnage des moyennes.....              | 3  |
| C. Distribution d'échantillonnage des pourcentages.....          | 3  |
| D. TD ECHANTILLONNAGE .....                                      | 5  |
| Chapitre II ESTIMATION.....                                      | 6  |
| A. Introduction.....                                             | 6  |
| B. Estimation ponctuelle .....                                   | 5  |
| 1.Moyenne.....                                                   | 5  |
| 2. Proportion.....                                               | 5  |
| 3. Variance.Ecart-type.....                                      | 5  |
| C. Estimation par intervalle de confiance.....                   | 7  |
| 1. De la moyenne .....                                           | 7  |
| 2. De la proportion.....                                         | 7  |
| 3. Exemples .....                                                | 7  |
| D.TD ESTIMATIONS PONCTUELLES ET PAR INTERVALLE DE CONFIANCE..... | 9  |
| Chapitre III TESTS STATISTIQUES.....                             | 10 |
| A. Principe des tests.....                                       | 11 |
| B. Test de comparaison à une valeur standard.....                | 11 |
| 1. Position de problème.....                                     | 11 |
| 2. Tests relatifs à une moyenne.....                             | 11 |
| 3. Tests relatifs à un fréquence ou un pourcentage.....          | 14 |
| 4. Remarque.....                                                 | 14 |
| C. Test de comparaison de 2 populations.....                     | 15 |
| 1. Test de comparaison de 2 moyennes.....                        | 15 |
| 2. Règle de comparaison de deux pourcentages.....                | 15 |
| D. Test du Khi-Deux.....                                         | 15 |
| E. TD LES TESTS STATISTIQUES.....                                | 16 |

## Chapitre 1 ECHANTILLONNAGE

### A. Le problème de l'échantillonnage

La théorie de l'échantillonnage consiste à déterminer des propriétés sur des échantillons prélevés dans une population dont on connaît déjà des propriétés. On ne considère ici que des échantillons aléatoires, c'est à dire constitués d'éléments pris au hasard dans une population. Le tirage des éléments d'un échantillon peut être fait sans remise; On dit qu'il est exhaustif. Sinon si le tirage est fait avec remise, on dit qu'il est non exhaustif ; dans ce cas les tirages sont indépendants. Dans la plupart des cas, la population ayant un grand effectif, dans laquelle on tire une faible proportion d'éléments, on assimile un tirage sans remise à un tirage avec remise.

### B. Distribution d'échantillonnage des moyennes

Considère une population ayant une certaine propriété avec une moyenne  $m$  et un écart-type  $\sigma$ . Soit  $\bar{X}$  la variable aléatoire qui à tout échantillon aléatoire prélevé avec remise et d'effectif  $n$  fixé, associe la moyenne de cet échantillon. Pour  $n$  suffisamment grand,

$\bar{X}$  suit approximativement la loi normale  $N(m; \frac{\sigma}{\sqrt{n}})$ .

Rem :

- $n$  suffisamment grand quand  $n = 30$ .
- si la population est-elle même normale, on peut utiliser ce résultat même si  $n$  est petit.
- lorsque les échantillons de taille  $n$  sont prélevés sans remise dans une population d'effectif  $N$ ,

on peut utiliser le résultat précédent en prenant  $\frac{\sigma}{\sqrt{n}} \sqrt{\frac{N-n}{N-1}}$  au lieu de  $\frac{\sigma}{\sqrt{n}}$

- il ne faut pas confondre l'écart-type  $\frac{\sigma}{\sqrt{n}}$  de la variable aléatoire qui prend pour valeurs les moyennes d'échantillons de taille  $n$ , et l'écart-type d'un échantillon.

### C. Distribution d'échantillonnage des pourcentages

Considérons une population dont un pourcentage  $p$  d'éléments possède une certaine propriété. Soit  $F$  la variable aléatoire, qui à tout échantillon aléatoire prélevé avec remise d'effectif  $n$  fixé, associe le pourcentage d'éléments de cet échantillon possédant cette propriété. Pour  $n$

Suffisamment grand,  $F$  suit approximativement la loi normale  $N(p, \sqrt{\frac{pq}{n}})$  avec  $q = 1 - p$ .

## D. TD ECHANTILLONNAGE

Ex 1 : après la correction d'une épreuve d'examen comportant un grand nombre de candidats, on constate que les notes ont pour moyenne 12 et pour écart-type 3. On se propose de prélever un échantillon aléatoire non exhaustif de 100 notes. 1) Quelle est la probabilité d'avoir la moyenne d'un tel échantillon supérieure à 12,5 ? 2) Quelle est la probabilité d'avoir la moyenne d'un tel échantillon comprise entre 12,5 et 12,9 ?

Ex 2 : un candidat a obtenu 55% des suffrages exprimés à une élection. 1) Quelle est la probabilité d'avoir, dans un échantillon aléatoire non exhaustif de taille  $n = 100$  prélevé parmi les suffrages exprimés, strictement moins de 50% de voix pour le candidat A ? 2) Même question mais avec  $n = 2000$ .

Ex 3 : une machine fabrique des disques pleins en grande série. On suppose que la variable aléatoire  $X$  qui, à chaque disque tiré au hasard, associe son diamètre suit la loi normale  $N(\mu, \sigma)$  où  $\mu = 12,8$  mm et  $\sigma = 2,1$  mm. 1) Quelle loi suit la variable aléatoire  $\bar{X}$ , qui à tout échantillon aléatoire non exhaustif de taille  $n = 49$ , associe la moyenne des diamètres des disques de cet échantillon ?

2) Déterminer un intervalle centré en 12,8 tel que la variable aléatoire prenne ses valeurs dans cet intervalle avec la probabilité 0,95. 3) On se propose de prélever un échantillon aléatoire non exhaustif de taille  $n$ . Déterminer  $n$  pour que la moyenne des diamètres des disques prélevés ne s'écarte pas de 12,8 de plus de 0,2 mm avec une probabilité de 0,95.

Ex 4 : une machine automatique fabrique des entretoises destinées à un montage de roulements. La longueur de ces entretoises doit être comprise, au sens large, entre 37,45 et 37,55 mm. La variable aléatoire  $X$ , qui associe à chaque entretoise sa longueur, est une variable gaussienne de moyenne 37,50 mm.

1) Quel doit être l'écart-type de la variable aléatoire  $X$  pour que 998 sur 1000 des pièces fabriquées soient bonnes ?

2) On prélève un échantillon non exhaustif dans la production. Quel doit être l'effectif de cet échantillon pour que la moyenne des longueurs des pièces prélevées appartienne à l'intervalle  $[37,495 ; 37,505]$  avec une probabilité de 0,95 ?

## Chapitre 2 ESTIMATION

### A. Introduction

C'est le problème inverse de l'échantillonnage ; c'est à dire connaissant des renseignements sur un on plusieurs échantillons, on cherche à en déduire des informations sur la population totale.

### B. Estimation ponctuelle

#### 1. Moyenne

De manière générale, on choisit la moyenne  $\bar{x}$  d'un échantillon prélevé au hasard dans une population comme meilleure estimation ponctuelle de la moyenne inconnue  $m$  de cette population.

#### 2. Proportion

De même, on choisit la proportion  $f_e$  des éléments possédant une certaine propriété dans un échantillon prélevé aléatoirement dans une population comme meilleure estimation ponctuelle de la proportion inconnue  $p$  des éléments de cette population ayant cette propriété.

#### 3. Variance. Ecart-type

On choisit le nombre  $\frac{n}{n-1} \sigma_e^2$  où  $n$  est l'effectif et  $\sigma_e^2$  la variance d'un échantillon prélevé au hasard dans une population, comme meilleure estimation ponctuelle de la variance inconnue  $\sigma^2$  de cette population et on prend  $\sqrt{\frac{n}{n-1}} \sigma_e$  comme meilleure estimation ponctuelle de l'écart-type  $\sigma$  inconnue de cette population.

### C. Estimation par intervalle de confiance

Les estimations ponctuelles sont hélas liées au choix de l'échantillon ; il faut donc rechercher un nouveau type d'estimation de la moyenne d'une population ou d'un pourcentage. On cherche des intervalles qui, généralement, à 95% ou 99% des cas, contiennent la moyenne  $m$  inconnue ou le pourcentage  $p$  d'une certaine propriété que possède la population.

#### 1. De la moyenne

##### a) 1er cas

Soit  $P$  la population : ~~on~~ la moyenne est inconnue

~~on~~ l'écart-type est connu

Soit un échantillon : ~~on~~ la moyenne est connue

$n$  l'effectif est connu

On se place dans le cas où l'on peut considérer que la variable aléatoire  $\bar{X}$ , qui à tout échantillon de taille  $n$  fixée, associe la moyenne de cet échantillon, suit une loi normale  $N(m; \frac{\sigma}{\sqrt{n}})$

Alors l'intervalle de confiance de la moyenne  $m$  de la population, avec ~~le~~ coefficient de confiance  $2\pi(t) - 1$ , lu dans la table de la loi normale centrée réduite  $N(0 ; 1)$  est :  $\left[ \bar{x} - t \frac{\sigma}{\sqrt{n}} ; \bar{x} + t \frac{\sigma}{\sqrt{n}} \right]$

Cette méthode conduit dans  $100(2\pi(t) - 1)$  cas sur 100, pourcentage choisi à l'avance, à un intervalle de confiance contenant  $m$ .

Les cas usuels les plus fréquents sont :

- coefficient de confiance 95% alors  $t = 1,96$
- coefficient de confiance 99% alors  $t = 2,58$ .

b) 2ème cas

Soit P la population :  $\mu$  la moyenne est inconnue

$\sigma$  L'écart-type est inconnu

Soit un échantillon :  $\bar{x}_e$  la moyenne est connue

$\sigma_e$  L'écart-type est connu

n l'effectif est connu et il est inférieur strictement à 30.

On se place dans le cas où l'on peut considérer que la variable aléatoire  $\bar{X}$ , qui à tout échantillon de taille n fixée,  $n < 30$ , associe la moyenne de cet échantillon, suit une loi de Student à n - 1 degrés de liberté.

Alors l'intervalle de confiance de la moyenne  $\mu$  de la population, avec le coefficient de confiance  $2\delta(t) - 1$ , lu dans la table de la loi de Student à n - 1 degrés de liberté est :  $\left[ \bar{x}_e - t \frac{\sigma_e}{\sqrt{n-1}} ; \bar{x}_e + t \frac{\sigma_e}{\sqrt{n-1}} \right]$

c) 3ème cas

Soit P la population :  $\mu$  la moyenne est inconnue

$\sigma$  L'écart-type est inconnu

Soit un échantillon :  $\bar{x}_e$  la moyenne est connue

$\sigma_e$  L'écart-type est connu

n l'effectif est connu et il est supérieur à 30.

On se place dans le cas où l'on peut considérer que la variable aléatoire  $\bar{X}$ , qui à tout échantillon de taille n fixée,  $n \geq 30$ , associe la moyenne de cet échantillon, suit une loi normale  $N(\mu; \frac{\sigma}{\sqrt{n}})$ .

Alors l'intervalle de confiance de la moyenne  $\mu$  de la population, avec le coefficient de confiance  $2\delta(t) - 1$ , lu dans la table de la loi normale centrée réduite  $N(0; 1)$  est :

$$\left[ \bar{x}_e - t \frac{\sigma_e}{\sqrt{n-1}} ; \bar{x}_e + t \frac{\sigma_e}{\sqrt{n-1}} \right]$$

## **2. De la proportion**

A l'aide d'un échantillon, on définit de même un intervalle de confiance de la proportion p inconnue d'une caractéristique de la population.

a) 1er cas

Soit P la population : p la proportion est inconnue

Soit un échantillon :  $f_e$  la proportion est connue

n l'effectif est connu et inférieur strictement à 30.

Alors l'intervalle de confiance de la proportion p de la population avec le coefficient de confiance  $2\delta(t) - 1$ , lu dans la table de la loi de Student à n - 1 degrés de liberté est :  $\left[ f_e - t \sqrt{\frac{f_e(1-f_e)}{n-1}}; f_e + t \sqrt{\frac{f_e(1-f_e)}{n-1}} \right]$

b) 2ème cas

Soit P la population : p la proportion est inconnue

Soit un échantillon :  $f_e$  la proportion est connue

n l'effectif est connu et supérieur à 30.

Alors l'intervalle de confiance de la proportion p de la population avec le coefficient de confiance

$2\pi(t) - 1$ , lu dans la table de la loi normale centrée réduite  $N(0 ; 1)$  est :  $\left[ f_e - t \sqrt{\frac{f_e(1-f_e)}{n-1}}; f_e + t \sqrt{\frac{f_e(1-f_e)}{n-1}} \right]$

### 3. Exemples

a) 1er exemple

Dans une population P de grand effectif, on prélève de manière non exhaustive, un échantillon de 100 personnes dont on note la masse en kg:

|          |    |    |    |    |    |
|----------|----|----|----|----|----|
| masse    | 62 | 64 | 68 | 70 | 74 |
| effectif | 5  | 18 | 42 | 27 | 8  |

- Calculer la moyenne et l'écart-type de cet échantillon:  $\bar{x} = 68$  kg  $\sigma_e = 3$  kg .

Donner un intervalle de confiance de la moyenne m des masses des personnes de P au coefficient de confiance 95% : nous sommes dans le 3ème cas

$$m \square \left[ 68 - 1,96 \frac{3}{\sqrt{100-1}}; 68 + 1,96 \frac{3}{\sqrt{100-1}} \right] = [67,4; 68,6]$$

c) 2ème exemple

Lors d'un contrôle de qualité sur une population d'appareils ménagers, au cours d'un mois de fabrication, on prélève de manière non exhaustive un échantillon de 1000 appareils. Après un test de conformité, on constate que 60 appareils ont un défaut. Donner un intervalle de confiance du pourcentage p d'appareils défectueux au risque de 5%.

$$p \square \left[ \frac{60}{1000} - 1,96 \sqrt{\frac{\frac{60}{1000} \left(1 - \frac{60}{1000}\right)}{1000-1}}; \frac{60}{1000} + 1,96 \sqrt{\frac{\frac{60}{1000} \left(1 - \frac{60}{1000}\right)}{1000-1}} \right] = [0,045 ; 0,075] = [4,5\% ; 7,5\%]$$

#### D. TD ESTIMATIONS PONCTUELLES ET PAR INTERVALLE DE CONFIANCE

Ex 1 : lors d'un concours radiophonique, on note  $X$  le nombre de réponses reçues chaque jour. On suppose que  $X$  suit une loi normale de paramètres  $m$  et  $\sigma$ . Durant les 10 premiers jours, on a obtenu :  $x_1 = 200$  ;  $x_2 = 240$  ;  $x_3 = 190$  ;  $x_4 = 150$  ;  $x_5 = 220$  ;  $x_6 = 180$  ;  $x_7 = 170$  ;  $x_8 = 230$  ;  $x_9 = 210$  et  $x_{10} = 210$ . Déterminer une estimation ponctuelle de  $m$  et  $\sigma$ .

Ex 2 : dans une population d'étudiants en sociologie, on a prélevé, indépendamment, deux échantillons de taille  $n_1 = 120$  et  $n_2 = 150$ . On constate que 48 étudiants de l'échantillon 1 et 66 étudiants de l'échantillon 2 ont une formation secondaire scientifique; Soit  $p$  la proportion d'étudiants de la population ayant une formation scientifique ; calculer trois estimations ponctuelles de  $p$ .

Ex 3 : dans une station-service, on suppose que le montant des chèques essence suit une loi normale de paramètres  $m$  et  $\sigma$ . On considère un échantillon de taille  $n = 50$  et on obtient une moyenne de 130 F et un écart-type de 28 F. Donner une estimation de  $m$  par un intervalle de confiance au niveau de confiance 95%.

Ex 4 : on donne la répartition des masses de 219 ressorts provenant d'une même fabrication :

| masses (g)     | [8,2 ; 8,4[ | [8,4 ; 8,6[ | [8,6 ; 8,8[ | [8,8 ; 9[ | [9 ; 9,2[ | [9,2 ; 9,4[ | [9,4 ; 9,6[ |
|----------------|-------------|-------------|-------------|-----------|-----------|-------------|-------------|
| Nb de ressorts | 9           | 21          | 39          | 63        | 45        | 27          | 15          |

$X$  donnant le poids d'un ressort provenant de cette fabrication donner une estimation de  $E(X)$  et  $V(X)$ . Donner pour  $E(X)$  un intervalle de confiance au niveau de confiance 95%.

Ex 5 : on veut estimer l'espérance mathématique  $m$  d'une variable aléatoire gaussienne  $X$  dont on connaît l'écart-type  $\sigma = 2,3$ . Quelle est la taille minimum de l'échantillon de  $X$  qui est à prendre si l'on veut obtenir pour  $m$  un intervalle de confiance de seuil 0,95 et dont la longueur ne dépasse pas 0,1.

Ex 5: dans un grand pays démocratique, un quotidien publie la côte du chef de l'état à partir d'un sondage réalisé auprès de 1000 personnes. Au mois de janvier la côte était de 38% d'opinion favorables, en février 36%. Et le journaliste de commenter « le chef de l'état perd 2 points ! ». Commenter ce commentaire...

## Chapitre 3 TESTS STATISTIQUES

### **A. Principe des tests**

Partons d'un exemple...Une machine fabrique des tiges d'acier. Si la machine est réglée correctement, l'utilisateur obtient une population de tiges de longueurs moyenne  $m$  et d'écart type  $\sigma$ . On désire savoir si cette machine se dérègle. Ainsi, on prélèvera, à intervalles réguliers, des échantillons pour mesurer la longueur effective des tiges. Nous faisons alors l'hypothèse  $H_0$  dite hypothèse nulle que la machine est bien réglée. On teste alors cette hypothèse: 2 cas se présentent :

- la machine est bien réglée, on accepte  $H_0$ .
- la machine est mal réglée, on rejette  $H_0$  et donc on accepte  $H_1$  dite hypothèse alternative.

**Définition** : un test statistique est une méthode permettant de prendre une décision à partir d'informations fournies par un échantillon. Cette décision dépend donc de l'échantillon. Ainsi qu'elle que soit la décision prise, on court deux sortes de risques :

- le risque dit de 1ère espèce noté  $\alpha$ , est la probabilité de rejeter l'hypothèse  $H_0$  alors qu'elle est vraie en réalité :  $\alpha = p(\text{rejeter } H_0 / H_0 \text{ vraie})$
- le risque dit de 2nde espèce noté  $\beta$ , est la probabilité d'accepter l'hypothèse  $H_0$  alors qu'elle est fautive en réalité :  $\beta = p(\text{accepter } H_0 / H_0 \text{ fautive})$ . Un test est bon si on arrive à minimiser  $\alpha$  et  $\beta$ .

### **B. Test de comparaison à une valeur standard**

#### **1. Position de problème**

On considère une population  $P$  sur laquelle on veut étudier un paramètre  $\gamma$  inconnue associé à un paramètre  $c$ . Sur un échantillon de taille  $n$ , on obtient  $\gamma_e$  connu. Sur la base de cette valeur observée  $\gamma_e$ , on se propose de comparer la vraie valeur  $\gamma$  à une valeur  $\gamma_0$  fixée à priori, constituant la valeur standard.

#### **2. Tests relatifs à une moyenne**

Soit une population  $P$  de grand effectif sur laquelle on étudie un caractère  $c$ . La moyenne  $m$  de  $c$  est inconnue. Sur un échantillon, on a trouvé une moyenne  $\bar{x}$ . On doit tester la moyenne  $m$  par rapport à une valeur notée  $m_0$  qui est la valeur standard.

##### **a) Test bilatéral**

Soit  $H_0$  : " $m=m_0$ " l'hypothèse nulle et  $H_1$  : " $m \neq m_0$ " l'hypothèse alternative Soit  $X$  la variable aléatoire prenant pour valeurs les moyennes des différents échantillons de taille  $n=30$ , alors on sait que  $X$  suit une  $N(m_0; \frac{\sigma}{\sqrt{n}})$ ,  $\sigma$  étant l'écart-type de la population  $P$ .

Il faut donc que  $X$  soit telle que  $p(m_0 - t\alpha \frac{\sigma}{\sqrt{n}} < X < m_0 + t\alpha \frac{\sigma}{\sqrt{n}}) = 1-\alpha$  d'où en faisant le changement de variable :  $T = \frac{X - m_0}{\frac{\sigma}{\sqrt{n}}}$  alors  $T$  suit une loi normale centrée réduite  $N(0,1)$  d'où

$p(-t\alpha < T < t\alpha) = 1-\alpha$  c'est à dire  $\pi(t\alpha) = 1 - \frac{\alpha}{2}$  d'où la règle du test bilatéral :

- On choisit un risque  $\alpha$
- on cherche dans la table de la loi normale centrée réduite  $N(0,1)$ ,  $t_\alpha$  tel que

$$\pi(t_\alpha) = 1 - \frac{\alpha}{2}$$

- soit  $\bar{m}_e$  la moyenne de l'échantillon de taille  $n$  alors si  $\bar{m}_e \in \left[ m_0 - t_\alpha \frac{\sigma}{\sqrt{n}} ; m_0 + t_\alpha \frac{\sigma}{\sqrt{n}} \right]$ , on accepte  $H_0$  avec le risque  $\alpha$  sinon on rejette  $H_0$  et donc on accepte  $H_1$  avec un risque  $\alpha$ .

Remarque : dans le cas usuel où  $\alpha = 5\%$  alors  $t_\alpha = 1,96$  et si  $\alpha = 1\%$  alors  $t_\alpha = 2,58$ .

Si  $\sigma$  est inconnu (ce qui est souvent le cas) alors on prend son estimateur ponctuel

$$\sqrt{\frac{n}{n-1}} \sigma_e \text{ Où } \sigma_e \text{ est l'écart-type de l'échantillon.}$$

### b) Tests unilatéraux

Règle du test unilatéral à gauche

L'hypothèse nulle est  $H_0 : "m = m_0"$  et l'hypothèse alternative est  $H_1 : "m > m_0"$  On peut la retrouver par exemple dans le cas d'un test de dépassement d'une norme.

- On choisit un risque  $\alpha$
- On cherche dans la table de la loi normale centrée réduite  $N(0;1)$   $t_\alpha$  tel que  $\pi(t_\alpha) = 1 - \alpha$
- Si  $\bar{m}_e \leq m_0 + t_\alpha \frac{\sigma}{\sqrt{n}}$  alors on accepte  $H_0$  sinon on refuse  $H_0$  et donc on accepte  $H_1$

Rem : dans les cas usuels : si  $\alpha = 5\%$  alors  $t_\alpha = 1,645$  ; si  $\alpha = 1\%$  alors  $t_\alpha = 2,33$

Règle du test unilatéral à droite

L'hypothèse nulle est :  $H_0 : "m = m_0"$  et l'hypothèse alternative est :  $H_1 : "m < m_0"$  On la retrouve dans les cas de tests de non égalité d'une norme.

- On choisit un risque  $\alpha$
- On cherche dans la table de la loi normale centrée réduite  $N(0;1)$   $t_\alpha$  tel que  $\pi(t_\alpha) = 1 - \alpha$
- Si  $\bar{m}_e > m_0 - t_\alpha \frac{\sigma}{\sqrt{n}}$  on accepte  $H_0$ , sinon on rejette  $H_0$  et donc on accepte  $H_1$  Dans ces deux cas, il est très fréquent qu'on ne connaisse pas  $\sigma$  ; on a alors  $\sigma = \sqrt{\frac{n}{n-1}} \sigma_e$

### 3. Tests relatifs à une fréquence ou un pourcentage

Tous les tests que l'on vient de voir restent valables ; il suffit de remplacer  $m$  par  $p$  (proportion inconnue dans la population  $P$ ),  $\bar{m}_e$  par  $f_e$  (proportion effective sur l'échantillon) et  $\frac{\sigma}{\sqrt{n}}$  par  $\sqrt{\frac{f_e(1-f_e)}{n-1}}$

### 4. Remarque

Un test bilatéral ne peut être utilisé à la place d'un test unilatéral dans la mesure où la recherche de  $t_\alpha$  ne se fait pas de la même façon. D'autre part le test bilatéral est un test « draconien ». C'est un test de non dépassement d'un côté ou de l'autre d'une norme. On peut imaginer par exemple la fabrication de pièces usinées. Les tests unilatéraux ne limitent eux que d'un seul côté.

## C. Test de comparaison de 2 populations

### 1. Test de comparaison de 2 moyennes

|                    | Population P1          | Population P2          |
|--------------------|------------------------|------------------------|
| Caractères Etudiés | C                      | C                      |
| Moyenne            | $m_1$<br>inconnus      | $m_2$<br>inconnus      |
| Ecart-type         | $\sigma_1$             | $\sigma_2$             |
|                    | Echantillon $e_1$      | Echantillon $e_2$      |
| Taille             | $n_1=30$               | $n_2=30$               |
| Moyenne            |                        |                        |
| Ecart-type         | $\sigma_{e1}$ inconnus | $\sigma_{e2}$ inconnus |

Règle du test de comparaison de 2 moyennes

L'hypothèse nulle est :  $H_0 : "m_1 = m_2"$  et l'hypothèse alternative est  $H_1 : "m_1 \neq m_2"$

- On choisit un risque  $\alpha$

- On cherche dans la table de la loi normale centrée réduite  $N(0;1)$   $t_{\alpha}$  tel que  $\pi(t_{\alpha}) = 1 - \alpha/2$

- Si  $\frac{\bar{x}_{e1} - \bar{x}_{e2}}{\sqrt{\frac{\sigma_1^2}{n_1-1} + \frac{\sigma_2^2}{n_2-1}}} \in [-t_{\alpha} ; t_{\alpha}]$  on accepte  $H_0$  sinon on rejette  $H_0$  et donc on accepte  $H_1$

- Si  $H_0$  est acceptée, on dit que la différence  $m_1 - m_2$  n'est pas significative au risque  $\alpha$

### 2. Règle de comparaison de deux pourcentages

|                  | Population P1     | Population P2     |
|------------------|-------------------|-------------------|
| Caractère étudié | C                 | C                 |
| Pourcentage      | $p_1$ inconnu     | $p_2$ inconnu     |
|                  | Echantillon $e_1$ | Echantillon $e_2$ |
| Taille           | $n_1=30$          | $n_2=30$          |
| Pourcentage      | $f_1$ connu       | $f_2$ connu       |

L'hypothèse nulle est  $H_0 : "p_1 = p_2"$  et l'hypothèse alternative  $H_1 : "p_1 \neq p_2"$

- On choisit un risque  $\alpha$

- On cherche dans la table de la loi normale centrée réduite  $N(0;1)$   $t_{\alpha}$  tel que  $\pi(t_{\alpha}) = 1 - \alpha/2$

• Soit  $f = \frac{n_1 f_1 + n_2 f_2}{n_1 + n_2}$  alors si  $\frac{f_1 - f_2}{\sqrt{f(1-f)(\frac{1}{n_1} + \frac{1}{n_2})}} \in [-\alpha; \alpha]$  on accepte  $H_0$  sinon on rejette  $H_0$  et on accepte donc  $H_1$ .

• Si  $H_0$  est acceptée, on dit que  $p_1 - p_2$  n'est pas significative au risque  $\alpha$ .

## D. Test du Khi-Deux

Ce test un peu différent des autres vu précédemment est un test de comparaison de valeurs pratiques à des valeurs théoriques. Pour avoir une bonne idée de l'utilisation d'un tel test, il faut penser à l'expérience suivante : on teste un dé à six faces pour savoir s'il n'est pas pipé. Les valeurs théoriques d'apparition de chaque faces sont de  $\frac{1}{6}$ . On lance ce dé un certain nombre de fois et on va trouver pour chaque face une valeur pratique d'apparition de chaque face. Grâce au test du Khi-Deux, on pourra savoir, en prenant un risque de première espèce, si oui ou non ce dé est pipé ou pas.

On considère une distribution à laquelle on associe un ensemble fini de probabilités qui sont, soit les probabilités d'un ensemble fini d'événements élémentaires, soit les probabilités de regroupements de classes statistiques. Les classes peuvent correspondre à des modalités qualitatives prises par une variable non numériques ou à des modalités quantitatives classiques. Les cas les plus classiques sont :

- 2 classes de probabilités données  $p$  et  $1-p$
- $k$  classes équiprobables
- $k$  classes dont les probabilités sont données à priori
- $n+1$  classes associées aux valeurs d'une variable binomiale de paramètres  $n$  et  $p$
- $n+1$  classes associées aux valeurs d'une variable aléatoire à valeurs entières positives, la  $n+1$  ème regroupant les valeurs supérieures ou égales à  $n$

Le but du test est de comparer globalement la distribution observée à la distribution théorique. Un risque d'erreur  $\alpha$  est fixé dans les conditions habituelles.

On note  $A_1, A_2, \dots, A_k$  les  $k$  classes. On dispose, d'une part les  $k$  probabilités théoriques  $p_j$ , d'autre part d'un échantillon de taille  $n$  dont on connaît les effectifs observés des classes.

L'hypothèse  $H_0$  est la conformité de la distribution réelle à la distribution théorique, et s'exprimera en affirmant, pour chaque classe, l'égalité de la probabilité réelle avec la probabilité théorique, soit  $H_0 = \ll p(A_1) = p_1, \dots, p(A_k) = p_k \gg$ . L'écart entre la distribution réelle et la distribution théorique est calculé en faisant intervenir pour chaque classe deux effectifs : l'effectif observé  $o_j$  et l'effectif théorique  $np_j$ . Une représentation graphique de la sorte est alors plus pratique :

|       |        |       |        |  |
|-------|--------|-------|--------|--|
| $o_1$ | $np_1$ | $o_j$ | $np_j$ |  |
|-------|--------|-------|--------|--|

L'exécution du test du  $\chi^2$  fait intervenir un paramètre qui est le nombre de degrés de liberté ddl et qui prend une valeur liée au nombre de cases : • dans le cas général,  $ddl = k - 1$  (nbre de cases moins un) • dans le cas d'une loi binomiale, d'une loi de Poisson ou d'une loi normale  $ddl = k - 2$

Hypothèse à tester :  $H_0 = \ll p(A_1) = p_1, \dots, p(A_k) = p_k \gg$

Ecart à tester :  $\chi^2 = \sum_{j=1}^k \frac{(o_j - np_j)^2}{np_j}$

Ecart critique :  $\chi^2_{1-\alpha}$  est lu dans la table de la loi du  $\chi^2$ , avec le nombre de degrés de liberté indiqué plus haut et le risque  $\alpha$  souhaité ( $1 - \alpha$  est donc le coefficient de confiance).

Règle : Si  $\chi^2 \leq \chi^2_{1-\alpha}$  alors  $H_0$  est accepté, sinon elle est refusée.

Une restriction d'emploi est cependant nécessaire : les effectifs théoriques  $np_j$  ne doivent pas être plus petits que 5. En cas de difficultés, la solution consiste à regrouper des classes contiguës pour que ces effectifs théoriques dépassent 5. En médecine on utilise un autre test du Khi-Deux, permettant même avec des très petits effectifs, qu'on ne peut même par regroupement faire dépasser 5, de conclure. C'est une espèce de test du Khi-Deux biaisé.

## E. TD LES TESTS STATISTIQUES

### Exercice 1:

Un fabricant de tubes à essais pour laboratoire fonde sa publicité sur le fait que la durée de vie de ses tubes correspond à 1500 heures de chauffage à l'aide d'un bec Bunsen. Un laboratoire de contrôle de publicité constate que sur 100 tubes à essais, la durée moyenne de vie est de 1485 heures de chauffage avec un écart-type de 110 heures. Au risque 5%, la durée de vie des tubes à essais est-elle différente de 1500 heures de chauffage ?

### Exercice 2:

Les moteurs des appareils électroménagers d'une marque M ont une durée de vie moyenne de 3000 heures avec un écart-type de 150 heures. À la suite d'une modification dans la fabrication des moteurs, le fabricant affirme que les nouveaux moteurs ont une durée de vie supérieure à celle des anciens. On a testé un échantillon de 50 nouveaux moteurs et on a trouvé une durée de vie moyenne de 3250 heures avec un écart-type égal à 150 heures. Les nouveaux moteurs apportent-ils une amélioration dans la durée de vie des appareils électroménagers au risque de 1% ?

### Exercice 3:

Un fabricant affirme qu'au moins 95 % de l'équipement qu'il fournit à un dépositaire est conforme au cahier des charges. L'examen d'un échantillon de 200 pièces fournies montre que 18 pièces sont défectueuses. Que penser de l'affirmation du fabricant au seuil de risque de 5 % ?

### Exercice 4:

On prélève dans la production d'une machine, un échantillon de 100 tiges métalliques. La moyenne des longueurs des tiges de cet échantillon est 100,04 cm avec un écart-type de 0,16 cm. La machine est réglée en principe pour obtenir des tiges de 100 cm. 1°) Au risque de 5 %, peut-on dire que la machine est bien réglée ? 2°) Reprendre la question précédente avec un risque de 1 %.

### Exercice 5:

Un chercheur a découvert un procédé efficace à 90 % pour prolonger la durée de vie des ballons à eau chaude. On teste son procédé sur 200 ballons. On constate qu'il est efficace pour 160 d'entre eux. L'affirmation du chercheur est-elle légitime au risque de 5% ?

### Exercice 6:

Un laboratoire annonce que l'un de ses médicaments est efficace à 95 %. Sur un échantillon de 400 personnes le traitement s'est révélé efficace sur 355 d'entre elles. Quel risque faut-il accepter si l'on considère que l'affirmation du laboratoire est légitime ?

### Exercice 7:

L'expérience suivante a été réalisée par Weldon : il a lancé un dé 315 672 fois, il a tiré 106 602 fois l'une des faces 5 ou 6. Peut-on accepter l'hypothèse selon laquelle le dés est équilibré, au risque de 5% ?

#### Exercice 8:

Dans une grande ville d'un pays donné, une enquête a été réalisée sur les dépenses mensuelles pour les loisirs. On a observé les résultats suivants:

- Sur 300 familles habitant le centre-ville, les dépenses mensuelles pour les loisirs sont en moyenne de 610 F avec un écart-type de 100 F.
- Sur 280 familles habitant la banlieue, les dépenses mensuelles pour les loisirs sont en moyenne de 640 F avec un écart-type de 120 F.

Peut-on dire au risque de 5 % que la part du budget familial consacré aux loisirs est différente suivant que la famille habite le centre-ville ou la banlieue ?

#### Exercice 9:

Une machine fabrique des pièces identiques. La moyenne des poids de 50 pièces prélevées dans la production est 68,2 grammes avec un écart-type de 2,5 grammes. On effectue un réglage sur la machine. On prélève un nouvel échantillon de 50 pièces. On trouve un poids moyen de 67,5 grammes avec un écart-type de 2,8 grammes. Peut-on affirmer, au risque 5 % que le réglage a modifié le poids des pièces ?

Exercice 10: Pour une élection, on effectue un sondage pour évaluer les intentions de vote en faveur du candidat Tayou. Dans la ville de Douala, sur 450 personnes interrogées, 52% ont l'intention de voter pour Tayou. Dans la ville de Yaoundé, sur 300 personnes interrogées, 49 % ont l'intention de voter pour Tayou. Au risque de 5%, y a-t-il une différence d'intention de vote dans ces deux villes ?

Exercice 11: Dans une population, soit  $p_1$ , la proportion d'hommes possédant le baccalauréat et  $p_2$  la proportion de femmes possédant le baccalauréat. Le tableau suivant correspond à la répartition de 200 individus choisis au hasard dans cette population.

|                         | hommes | femmes |
|-------------------------|--------|--------|
| Possèdent le bac        | 32     | 26     |
| Ne possèdent pas le bac | 64     | 78     |

Peut-on affirmer au risque 0,05, que  $p_1$  et  $p_2$  sont significativement différents ?

Exercice 12 : on considère un prisme dont les bases sont deux triangles équilatéraux et constitué d'une matière parfaitement homogène. On désigne par  $A_i$ , les trois faces latérales et par  $B_i$  les 2 bases. On lance le prisme 500 fois et on constate que le prisme est tombé :

| faces                 | $A_1$ | $A_2$ | $A_3$ | $B_1$ | $B_2$ |
|-----------------------|-------|-------|-------|-------|-------|
| Nombres d'apparitions | 111   | 113   | 118   | 81    | 77    |

Tester l'hypothèse selon laquelle les 3 faces latérales et les deux bases ont la même probabilité 1/5.

Exercice 13 : Une variable aléatoire  $X$  ne peut prendre que les valeurs 0, 1, 2, 3, 4. On veut tester l'hypothèse selon laquelle  $X$  suit une loi binomiale  $B(4; \frac{1}{3})$ . On fait pour cela 324 épreuves indépendantes de  $X$  qui conduisent aux résultats suivants :

|                                           |    |     |    |    |    |
|-------------------------------------------|----|-----|----|----|----|
| Valeurs $i$                               | 0  | 1   | 2  | 3  | 4  |
| Nombre de fois où $X$ prend la valeur $i$ | 67 | 122 | 94 | 28 | 13 |

Quelles conclusions peut-on émettre ?

Exercice 14 : Dans une PME, durant les 60 derniers jours ouvrables, on a relevé chaque jour le nombre de salariés en arrêt de travail et consigné les résultats dans le tableau suivant :

|                                              |   |   |   |    |   |   |   |   |   |   |
|----------------------------------------------|---|---|---|----|---|---|---|---|---|---|
| $x_i$ nombre de salariés en arrêt de travail | 0 | 1 | 2 | 3  | 4 | 5 | 6 | 7 | 8 | 9 |
| $n_i$ nombre de jours d'observation          | 9 | 9 | 8 | 11 | 8 | 6 | 5 | 3 | 0 | 1 |

Peut-on dire au risque de 5% que le nombre de jours d'arrêt de travail suit une loi de Poisson ?

Exercice 15 : Les tailles de 1000 tiges exprimées en cm ont été relevées dans le tableau suivant :

|          |     |     |     |     |     |     |     |     |     |     |     |     |     |     |     |     |
|----------|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|-----|
| taille   | 3,3 | 3,4 | 3,5 | 3,6 | 3,7 | 3,8 | 3,9 | 4   | 4,1 | 4,2 | 4,3 | 4,4 | 4,5 | 4,6 | 4,7 | 4,8 |
| effectif | 2   | 1   | 2   | 4   | 10  | 22  | 60  | 148 | 235 | 207 | 160 | 92  | 41  | 11  | 2   | 3   |

Tester l'hypothèse selon laquelle la taille des tiges suit une loi normale, dont on cherchera aux préalables les paramètres. (risque 5%).

Exercice 16 : Les mesures de tension de rupture de 300 fils de Kevlar ont conduit aux résultats suivants :

|          |               |               |               |               |               |               |
|----------|---------------|---------------|---------------|---------------|---------------|---------------|
| Taille   | [0,5 ; 0,64[  | [0,64 ; 0,78[ | [0,78 ; 0,92[ | [0,92 ; 1,06[ | [1,06 ; 1,20[ | [1,20 ; 1,34[ |
| Effectif | 1             | 2             | 9             | 25            | 37            | 53            |
| Taille   | [1,34 ; 1,48[ | [1,48 ; 1,62[ | [1,62 ; 1,76[ | [1,76 ; 1,90[ | [1,90 ; 2,04[ | [2,04 ; 2,18[ |
| Effectif | 56            | 53            | 25            | 19            | 16            | 4             |


Tester l'hypothèse selon laquelle la tension de rupture suit une loi normale, dont on cherchera aux préalables les paramètres, au risque de 5%.

## Analyse des données

L'**analyse des données** (aussi appelée **analyse exploratoire des données** ou **AED**) est une famille de méthodes statistiques dont les principales caractéristiques sont d'être multidimensionnelles et descriptives. Dans l'acception française, la terminologie « analyse des données » désigne donc un sous-ensemble de ce qui est appelé plus généralement la [statistique multivariée](#). Certaines méthodes, pour la plupart [géométriques](#), aident à faire ressortir les relations pouvant exister entre les différentes données et à en tirer une information statistique qui permet de décrire de façon plus succincte les principales informations contenues dans ces données. D'autres techniques permettent de regrouper les données de façon à faire apparaître clairement ce qui les rend [homogènes](#), et ainsi mieux les connaître.

L'analyse des données permet de traiter un nombre très important de données et de dégager les aspects les plus intéressants de la structure de celles-ci. Le succès de cette discipline dans les dernières années est dû, dans une large mesure, aux [représentations graphiques](#) fournies. Ces graphiques peuvent mettre en évidence des relations difficilement saisies par l'analyse directe des données ; mais surtout, ces représentations ne sont pas liées à une opinion « a priori » sur les [lois](#) des phénomènes analysés contrairement aux méthodes de la statistique classique.

Les fondements mathématiques de l'analyse des données ont commencé à se développer au début du <sup>xx</sup>e siècle, mais ce sont les [ordinateurs](#) qui ont rendu cette discipline opérationnelle, et qui en ont permis une utilisation très étendue. Mathématiques et informatique sont ici intimement liées.



- 1 Définition
- 2 Histoire
- 3 Domaines d'application
- 4 Analyse par réduction des dimensions
  - o 4.1 Analyse en composantes principales
  - o 4.2 Analyse factorielle des correspondances
  - o 4.3 Analyse des correspondances multiples
  - o 4.4 Analyse canonique
  - o 4.5 Positionnement multidimensionnel
  - o 4.6 Analyse Factorielle Multiple
    - 4.6.1 Exemples d'application
    - 4.6.2 Intérêt
  - o 4.7 Autres méthodes
- 5 Analyse par classification
  - o 5.1 Classification automatique
    - 5.1.1 Classification « à plat »
    - 5.1.2 Classification hiérarchique
  - o 5.2 Analyse factorielle discriminante
- 6 Analyse des données et régressions
  - o 6.1 Approche PLS
  - o 6.2 Régressions

## Définition

---

Dans l'acception française, la terminologie « analyse des données » désigne un sous-ensemble de ce qui est appelé plus généralement la [statistique multivariée](#). L'analyse des données est un ensemble de techniques descriptives, dont l'outil mathématique majeur est l'algèbre matricielle, et qui s'exprime sans supposer a priori un modèle probabiliste

Elle comprend l'[analyse en composantes principales](#) (ACP), employée pour des données quantitatives, et ses méthodes dérivées : l'[analyse factorielle des correspondances](#) (AFC) utilisée sur des données qualitatives (tableau d'association) et l'[analyse factorielle des correspondances multiples](#) (AFCM ou ACM) généralisant la précédente. L'[analyse canonique](#) et l'[analyse canonique généralisée](#), qui sont plus des cadres théoriques que des méthodes aisément applicables, étendent plusieurs de ces méthodes et vont au-delà des techniques de description. L'Analyse Factorielle Multiple est adaptée aux tableaux dans lesquels les variables sont structurées en groupes et peuvent être quantitative et/ou qualitatives. La [classification automatique](#), l'[analyse factorielle discriminante](#) (AFD) ou [analyse discriminante](#) permettent d'identifier des groupes homogènes au sein de la population du point de vue des variables étudiées.

En marge de l'analyse des données, l'[analyse en composantes indépendantes](#) (ACI), plus récente, issue de la physique du signal et connue initialement comme [méthode de séparation aveugle de source](#), est plus proche intuitivement des méthodes de classification non supervisée. L'[iconographie des corrélations](#) pour des données qualitatives et quantitatives, organise les corrélations entre variables sous la forme de graphes. L'analyse inter-batterie de Tucker est intermédiaire entre l'analyse canonique et l'analyse en composantes principales, l'analyse des redondances appelée aussi analyse en composantes principales sur variables instrumentales se rapproche de la régression puisque les variables d'un des groupes analysés

sont considérées comme dépendantes, les autres comme indépendantes, et que la fonction à maximiser est une somme de coefficients de corrélation entre les deux groupes.

En dehors de l'école française, l'analyse des données multivariée est complétée par la méthode de [poursuite de projection](#) de [John Tukey](#), et les méthodes de quantification de [Chikio Hayashi](#), dont la quantification de type III est analogue à l'analyse de correspondances. L'analyse factorielle anglo-saxonne, ou *Factor Analysis*, est proche de l'analyse en composantes principales, sans être équivalente, car elle utilise les techniques de [régression](#) pour découvrir les « variables latentes »<sup>note 2</sup>.

Ces procédés permettent notamment de manipuler et de synthétiser l'information provenant de tableaux de données de grande taille, à l'aide de l'estimation des [corrélations](#) entre les variables que l'on étudie. L'outil statistique utilisé est la [matrice des corrélations](#) ou la [matrice de variance-covariance](#).

## Histoire

---

Les pères de l'analyse des données modernes sont [Jean-Paul Benzécri](#), [Louis Guttman](#), [Chikio Hayashi](#) (concepteur des méthodes dénommées *Data Sciences*), Douglas Carroll et R.N. Shepard

Mais bien avant leur temps, les techniques de base de l'analyse des données sont déjà connues. Les tableaux de contingences, par exemple, sont présents tôt dans l'histoire : l'[invincible armada](#) est décrite, par Paz Salas et Alvarez dans un livre publié en 1588, sous la forme d'un tableau où les lignes représentent les flottes de navires et les colonnes les caractéristiques telles que le tonnage, le nombre de gens d'armes, etc. Nicolas de Lamoignon de Basville, intendant du roi [Louis XIV](#), compte et caractérise les couvents et les monastères de la région du [Languedoc](#) en 1696.

La classification trouve son maître, entre 1735 et 1758, en la personne de [Carl von Linné](#) qui met en place à cette époque les fondements de la nomenclature binomiale et la taxinomie moderne. Robert R. Sokal et Peter H.A. Sneath présentent en 1963 des méthodes quantitatives appliquées à la [taxinomie](#).

Les notions requises pour une analyse des données modernes commencent à être maîtrisées au début du XIX<sup>e</sup> siècle<sup>i6</sup>. [Adolphe Quetelet](#), astronome, statisticien belge, exploite ce qu'il connaît de la loi gaussienne à l'anthropométrie pour examiner la dispersion autour de la moyenne (la [variance](#)) des mesures des tailles d'un groupe d'hommes. Puis, [Francis Galton](#), parce qu'il veut étudier la taille des pères et des fils, s'intéresse à la variation conjointe (la [covariance](#) et la [corrélation](#)) de deux grandeurs, qui est à l'origine de ce qu'on appelle aujourd'hui la régression.

Quand [Karl Pearson](#) et [Raphael Weldon](#) s'emparent des travaux de Francis Galton, ils peuvent généraliser la régression de Galton aux données multidimensionnelles, puis Karl Pearson a l'idée de changer les axes de présentation pour les exprimer en fonction de variables indépendantes en 1901, établissant ainsi les prémisses de l'[analyse en composantes principales](#). Celle-ci est développée en 1933 par [Harold Hotelling](#) qui définit en 1936 l'[Analyse canonique](#).

Marion Richardson et Frederic Kuder en 1933, cherchant à améliorer la qualité des vendeurs de *Procter & Gamble*, utilisent ce qu'on appelle maintenant l'[algorithme](#) (*Reciprocal averaging*), bien connu en ACP<sup>i7</sup>. [Herman Otto Hirschfeld](#), dans sa publication *A connection between correlation and contingency*, découvre les équations de l'analyse des correspondances<sup>i8</sup>.

C'est la [psychométrie](#) qui développe le plus l'analyse des données. Quand [Alfred Binet](#) définit ses tests psychométriques pour mesurer l'intelligence chez l'enfant, [Charles Spearman](#) s'en accapare pour définir, en 1904, sa théorie des *facteurs* général et spécifique qui mesurent l'aptitude générale et l'aptitude particulière à une activité, nécessaires pour mener à bien cette activité<sup>i9</sup>. [Louis Leon Thurstone](#) met au point sous forme matricielle les équations induites par la théorie des *facteurs*, en 1931, et la complète par l'étude du terme d'erreur<sup>i10</sup>. Il introduit aussi la notion d'axes principaux d'inertie. En 1933, Harold Hotelling propose l'utilisation de l'itération pour la diagonalisation des matrices et la recherche des vecteurs propres<sup>i9</sup>.

Jean-Paul Benzécri et [Brigitte Escofier-Cordier](#) proposent l'Analyse factorielle des correspondances en 1962-65, mais en 1954 Chikio Hayashi a déjà établi les fondations de cette méthode sous le nom Quantification de type III<sup>i4</sup>.

L'analyse des correspondances multiples est initiée par [Louis Guttman](#) en 1941, [Cyril Burt](#) en 1950 et à Chikio Hayashi en 1956. Cette technique est développée au [Japon](#) en 1952 par Shizuhiko Nishisato sous la dénomination *Dual Scaling* et aux [Pays-Bas](#) en 1990 sous le nom de *Homogeneity analysis* par le collectif Albert Gifi.

L'avènement de l'ordinateur, et surtout du micro-ordinateur, est un saut technologique qui rend possible les calculs complexes, les diagonalisations, les recherches de valeurs propres sur de grands tableaux de données, avec des délais d'obtention de résultats très courts par rapport à ce qui est fait dans le passé.

## Domaines d'application

---

L'analyse des données est utilisée dans tous les domaines dès lors que les données se présentent en trop grand nombre pour être appréhendées par l'esprit humain.

En [sciences humaines](#), cette technique est utilisée pour cerner les résultats des [enquêtes d'opinion](#) par exemple avec l'Analyse des correspondances multiples ou l'Analyse factorielle des correspondances. La [sociologie](#) compte beaucoup sur l'analyse des données pour comprendre la vie et le développement de certaines populations comme celles du Liban dont l'évolution est montrée par deux études faites en 1960 et 1970, présentées par Jean-Paul Benzécri, et dont la structure du niveau de vie et de son amélioration sont décortiquées à l'aide de l'analyse en composantes principales. L'analyse des correspondances multiples est souvent utilisée en [sociologie](#) pour analyser les réponses à un questionnaire. Les sociologues Christian Baudelot et Michel Gollac utilisent une analyse des correspondances multiples pour étudier le rapport des Français à leur travail. S'inspirant de [Pierre Bourdieu](#) pour étudier un « champ » spécifique, le sociologue Frédéric Lebaron emploie une ACM pour analyser le champ des économistes français et Hjellbrekke et ses coauteurs appliquent la même méthode pour analyser le champ des élites norvégiennes. De même, François Denord et ses coauteurs utilisent une ACM pour analyser le champ du pouvoir en France à partir du Who's Who. Toujours dans les travaux qui s'inspirent de Pierre Bourdieu, on peut aussi prendre comme exemple l'analyse du champ du cinéma français par Julien Duval. Les [linguistes](#) utilisent l'[analyse de texte](#) et les techniques d'analyse des données pour situer un député sur l'échiquier politique en examinant la fréquence d'usage de certains mots. Brigitte Escofier-Cordier a étudié quelques éléments du vocabulaire employé dans la pièce de Racine, [Phèdre](#), pour montrer comment l'auteur se sert des mots pour ancrer ses personnages dans la hiérarchie sociale. En [économie](#), les bilans des entreprises ont été étudiés par C. Desroussilles pour décrire la structure et la taille de ces organismes à l'aide de la classification ascendante et de l'analyse des correspondances. La structure de la consommation des ménages dans la CEE, est présentée par Jean-Paul Benzécri *et al.* sur les deux axes d'une analyse des correspondances et une première étape dans l'établissement d'une nomenclature des activités économiques dans

l'industrie montre l'utilité d'une analyse des correspondances et de la classification hiérarchique dans ce type d'opération.

Dans le domaine des sciences et techniques, certains chercheurs adoptent ces méthodes statistiques pour déchiffrer plusieurs caractéristiques du [génom](#). D'autres se servent de l'analyse des données pour mettre en place un processus nécessaire à la [reconnaissance des visages](#). En [épidémiologie](#), l'[Inserm](#) met à disposition ses données qu'ont exploitées Husson et al. via l'Analyse factorielle des correspondances pour décrire les tranches d'âges en [France](#) en fonction de leurs causes de [mortalité](#). Jean-Paul Benzécri donne aussi des exemples de l'usage de l'analyse des correspondances dans le cadre de l'[apprentissage](#), de l'[hydrologie](#), de la [biochimie](#). Un exemple dans les [sciences de l'environnement](#) est celui de l'étude des traces de métaux dans le blé en fonction des sols cultivés, qui utilise l'analyse des corrélations canoniques considérée habituellement comme un outil plutôt théorique. L'Observatoire des Maladies du Bois de la Vigne a cherché, dans la première décennie de ce siècle, à mesurer l'évolution de trois maladies de la vigne en pratiquant, entre autres méthodes, l'analyse des correspondances multiples et l'analyse en composantes principales dans un projet d'[épidémiologie végétale](#).

Le domaine du sport est très friand de statistiques : un médecin du sport s'interroge sur l'âge des pratiquants, leurs motivations et le sport qu'ils pratiquent. Dans une autre étude le sport s'intéresse aux motivations des sportifs lesquelles vont de l'amitié et la camaraderie à l'affirmation de soi représentées sur un axe, et de la nature et la beauté à la combativité sur un second axe. Le sociologue cherche à savoir si la sociabilité des adeptes d'un sport est influencée par sa pratique, la [biométrie](#) humaine caractérise la [morphologie](#) du sportif selon le sport qu'il pratique, et dans le cas de [sports collectifs](#) le poste qu'il occupe dans l'équipe, etc.

La [microfinance](#) s'est aussi emparée de l'analyse des données pour évaluer les risques et définir les populations emprunteuses. L'industrie de l'[assurance](#) se sert de l'analyse des données pour la connaissance des risques et la tarification à priori

### Analyse par réduction des dimensions

La représentation des données multidimensionnelles dans un espace à dimension réduite est le domaine des analyses factorielles, analyse factorielle des correspondances, analyse en composantes principales, analyse des correspondances multiples. Ces méthodes permettent de représenter le nuage de points à analyser dans un plan ou dans un espace à trois dimensions, sans trop de perte d'information, et sans hypothèse statistique préalable. En [mathématiques](#), elles exploitent le [calcul matriciel](#) et l'analyse des vecteurs et des [valeurs propres](#).

### Analyse en composantes principales

: [Analyse en composantes principales](#).




fig.02 - ACP : contribution des variables aux deux premières composantes principales d'après une présentation effectuée par FG Carpentier sur sa page « Analyse en composantes principales avec R » à l'aide du logiciel [R](#) sur les données Budgets-Temps de l'ONU, étude effectuée en 1967




fig.01 - ACP : contribution des individus aux deux premières composantes principales d'après une présentation effectuée par FG Carpentier sur sa page « Analyse en composantes principales avec R » à l'aide du logiciel [R](#) sur les données Budgets-Temps de l'ONU, étude effectuée en 1967

L'analyse en composantes principales est utilisée pour réduire  $p$  variables corrélées en un nombre  $q$  de variables non corrélées de telles manières que les  $q$  variables soient des combinaisons linéaires des  $p$  variables initiales, que leur variance soit maximale et que les nouvelles variables soient orthogonales entre elles suivant une distance particulière. En ACP, les variables sont quantitatives.

Les composantes, les nouvelles variables, définissent un sous-espace à  $q$  dimensions sur lequel sont projetés les individus avec un minimum de pertes d'information. Dans cet espace le nuage de points est plus facilement représentable et l'analyse est plus aisée. En analyse des correspondances, la [représentation](#) des individus et des variables ne se fait pas dans le même espace.

La mesure de la qualité de représentation des données peut être effectuée à l'aide du calcul de la contribution de l'inertie de chaque composante à l'inertie totale. Dans l'exemple donné sur les deux images ci-contre, la première composante participe à hauteur de 45,89 % à l'inertie totale, la seconde à 21,2 %.

Plus les variables sont proches des composantes et plus elles sont corrélées avec elles.

L'analyste se sert de cette propriété pour l'interprétation des axes. Dans l'exemple de la fig.01 les deux composantes principales représentent l'activité majeure et l'activité secondaire la plus fréquente dans lesquelles les Femmes (F) et les Hommes (H) mariés (M) ou célibataires (C) aux Usa (U) ou en Europe de l'Ouest (W) partagent leur journée. Sur la fig.02 est illustré le cercle des corrélations où les variables sont représentées en fonction de leur projection sur le plan des deux premières composantes. Plus les variables sont bien représentées et plus elles sont proches du cercle. Le cosinus de l'angle formé par deux variables est égal au coefficient de corrélation entre ces deux variables.

De même, plus l'angle engendré par l'individu et l'axe de la composante est petit et mieux l'individu est représenté. Si deux individus, bien représentés par un axe, sont proches, ils sont proches dans leur espace. Si deux individus sont éloignés en projection, ils sont éloignés dans leur espace.

## Analyse factorielle des correspondances

### Analyse factorielle des correspondances.




fig.04 - Analyse factorielle des correspondances (plan factoriel F2-F3) des données des élections régionales de 2004 en Île-de-France - (ref F.G. Carpentier - Université de Brest - France)




fig.03 - Analyse factorielle des correspondances (plan factoriel F1-F2) des données des élections régionales de 2004 en Île-de-France (ref F.G. Carpentier - Université de Brest - France)

Le but de l'AFC - définie par Jean-Paul Benzécri et ses équipes - est de trouver des liens ou correspondances entre deux variables qualitatives (nominales). Cette technique traite les [tableaux de contingence](#) de ces deux variables. En fait, une AFC est une ACP sur ces

tableaux dérivés du tableau initial munis de la métrique du  $\chi^2$ . Le principe de l'AFC est identique à celui de l'ACP. Les axes explicatifs qui sous-tendent le tableau de fréquences de deux variables qualitatives sont recherchés et présentés dans un graphique.

Il y a au moins deux différences entre une ACP et une AFC : le premier est qu'on peut représenter les individus et les variables dans un même graphique, la seconde concerne la similarité. Deux points-lignes sont proches dans la représentation graphique, si les profils-colonnes sont similaires. Par exemple sur le graphique de la fig.03, Paris et les Yvelines ont voté d'une manière similaire, ce qui n'est pas évident quand on regarde le tableau de contingence initial puisque le nombre de votants est assez différent dans les deux départements. De même, deux points-colonnes (dans l'exemple des figures 03 et 04 les points

colonnes sont les candidats) sont proches graphiquement si les profils-lignes sont similaires. Dans l'exemple (fig.04), les départements ont voté pour Bayrou et Le Pen de la même manière. Les points-lignes et les points-colonnes ne peuvent pas être comparés d'une manière simple.

En ce qui concerne l'interprétation des facteurs, Jean-Paul Benzécri est très clair :

« ..Interpréter un axe, c'est trouver ce qu'il y a d'analogie d'une part entre tout ce qui est écrit à droite de l'origine, d'autre part entre tout ce qui s'écarte à gauche ; et exprimer, avec concision et exactitude, l'opposition entre les deux extrêmes.....Souvent l'interprétation d'un facteur s'affine par la considération de ceux qui viennent après lui. »

— Jean-Paul Benzécri,

*L'analyse des données : 2 l'analyse des correspondances*

La qualité de la représentation graphique peut être évaluée globalement par la part

du expliquée par chaque axe (mesure de la qualité globale), par l'inertie d'un point projetée sur un axe divisé par l'inertie totale du point (mesure de la qualité pour chaque modalité), la contribution d'un axe à l'inertie totale ou le rapport entre l'inertie d'un nuage (profils lignes ou profils colonnes ) projeté sur un axe par l'inertie totale du même nuage.

### Analyse des correspondances multiples

: [Analyse des correspondances multiples](#).




fig.05 - Analyse des correspondances Multiples : contributions des modalités aux deux premiers axes (plan factoriel F1-F2) des données d'une enquête sur les OGM effectuée en 2008 par Agrocampus - Université de Rennes - France auprès de 135 personnes - (voir F.Husson *et al.*)




fig.06 - Analyse des correspondances Multiples : contributions des individus aux deux premiers axes (plan factoriel F1-F2) des données d'une enquête sur les OGM effectuée en 2008 par Agrocampus - Université de Rennes - France auprès de 135 personnes - (voir F.Husson *et al.*)

L'Analyse des Correspondances Multiples (ACM) est une extension de l'AFC.

L'ACM se propose d'analyser  $p$  ( $p \geq 2$ ) variables qualitatives d'observations sur  $n$  individus. Comme il s'agit d'une analyse factorielle elle aboutit à la représentation des données dans un espace à dimensions réduites engendré par les facteurs. L'ACM est l'équivalent de l'ACP pour les variables qualitatives et elle se réduit à l'AFC lorsque le nombre de variables qualitatives est égal à 2.

Formellement, une ACM est une AFC appliquée sur le [tableau disjonctif complet](#), ou bien une AFC appliquée sur le [tableau de Burt](#), ces deux tableaux étant issus du tableau initial. Un tableau disjonctif complet est un tableau où les variables sont remplacées par leurs modalités et les éléments par 1 si la modalité est remplie 0 sinon pour chaque individu. Un tableau de Burt est le tableau de contingence des  $p$  variables prises deux à deux.

L'interprétation se fait au niveau des modalités dont les proximités sont examinées. Les valeurs propres ne servent qu'à déterminer le nombre d'axes soit par la méthode du coude soit

en ne prenant que les valeurs propres supérieures à . La contribution de l'inertie des modalités à celle des différents axes est analysée comme en AFC.

L'utilisation de variables supplémentaires, variables qui ne participent pas à la constitution des axes ni au calcul des valeurs propres, peut aider à interpréter les axes.

La qualité de la représentation d'un individu sur un axe factoriel est mesurée

par où est l'angle formé par la projection du vecteur individu sur l'espace factoriel avec l'axe factoriel. Plus la valeur de est proche de 1 plus la qualité est bonne.

## Analyse canonique

: [Analyse canonique des corrélations](#).




fig.08 - Analyse Canonique des Corrélations : matrices des corrélations sur les données nutrimouse du package CCA de R d'après l'article d'Ignacio et al. dans *Journal of Statistical Software* (volume 23, issue 12, January 2008)




fig.07 - Analyse Canonique des Corrélations : représentation des variables et des individus dans le plan des deux premières variables canoniques sur les données nutrimouse du package CCA de R d'après l'article d'Ignacio et al. dans *Journal of Statistical Software* (volume 23, issue 12, January 2008)

L'analyse canonique permet de comparer deux groupes de variables quantitatives appliqués tous deux sur les mêmes individus. Le but de l'analyse canonique est de comparer ces deux groupes de variables pour savoir s'ils décrivent un même phénomène, auquel cas l'analyste pourra se passer d'un des deux groupes de variables.

Un exemple parlant est celui des analyses médicales effectuées sur les mêmes échantillons par deux laboratoires différents. L'analyse canonique généralise des méthodes aussi diverses que la [régression linéaire](#), l'[analyse discriminante](#) et l'[analyse factorielle des correspondances](#).

Plus formellement, si  $X$  et  $Y$  sont deux groupes de variables, l'analyse canonique cherche des couples de vecteurs  $u$  et  $v$ , combinaisons linéaires des variables

de  $X$  et  $Y$  respectivement, le plus corrélées possibles. Ces variables sont dénommées variables canoniques. Dans l'espace ce sont les vecteurs propres des

projections  $P_X$  et  $P_Y$  respectivement sur les sous espace de  $X$  et  $Y$ , où  $p$  et  $q$  représentent le nombre de variables des deux groupes, engendrés par les deux ensembles de

variables.  $r$  mesure la corrélation entre les deux groupes. Plus cette mesure est élevée, plus les deux groupes de variables sont corrélés et plus ils expriment le même phénomène sur les individus.

Dans l'illustration de la fig.08, les corrélations entre les variables à l'intérieur des deux groupes sont représentées par les corrélogrammes du haut, la corrélation entre les deux groupes est expliquée au-dessous. Si la couleur dominante était vert clair aucune corrélation n'aurait été détectée. Sur la fig.07, les deux groupes de variables sont rassemblés dans le cercle des corrélations rapportés aux deux premières variables canoniques.

Enfin l'[analyse canonique généralisée](#) au sens de Carroll (d'après J.D.Carroll) étend l'analyse canonique ordinaire à l'étude de  $p$  groupes de variables ( $p > 2$ ) appliquées sur le même espace des individus. Elle admet comme cas particuliers l'ACP, l'AFC et l'ACM, l'analyse canonique simple, mais aussi la [régression simple](#), et multiple, l'[analyse de la variance](#), l'[analyse de la covariance](#) et l'analyse discriminante.

## Positionnement multidimensionnel

: [Positionnement multidimensionnel](#).




fig.09 - MDS métrique (analyse en positionnement multidimensionnel) de quelques villes mondiales via une matrice des distances inter-villes, avec l'aide du guide disponible sur Quick-R




fig.10 - MDS non métrique (analyse en positionnement multidimensionnel) de quelques villes mondiales classées par ordre des distances (1 la plus petite distance, 21 la plus grande distance) avec l'aide du guide disponible sur Quick-R

Pour utiliser cette technique les tableaux ne doivent pas être des variables caractéristiques d'individus mais des « distances » entre les individus. L'analyste souhaite étudier les similarités et les dissimilarités entre ces individus.

Le positionnement multidimensionnel (*multidimensional scaling* ou MDS) est donc une méthode factorielle applicable sur des matrices de [distances](#) entre individus. Cette méthode ne fait pas partie de ce qu'on nomme habituellement l'analyse des données « à la française ». Mais elle a les mêmes caractéristiques que les méthodes précédentes : elle est fondée sur le calcul matriciel et ne demande pas d'hypothèse probabiliste. Les données peuvent être des mesures de  $p$  variables quantitatives sur  $n$  individus, et dans ce cas l'analyste calcule la

matrice des distances ou bien directement un tableau des distances entre individus.

Dans le cas classique dit métrique, la mesure des [dissimilarités](#) utilisée est une distance euclidienne. Elle permet d'approximer les dissimilarités entre individus dans l'espace de dimension réduite. Dans le cas non métrique les données sont ordinales, de type rang.

L'analyste s'intéresse plus à l'ordre des dissimilarités plutôt qu'à leur étendue. La MDS non métrique utilise un indice de dissimilarité (équivalent à une distance mais sans l'inégalité triangulaire) et permet l'approximation de l'ordre des entrées dans la matrice des dissimilarités par l'ordre des distances dans l'espace de dimension réduite.

Comme en ACP, il faut déterminer le nombre de dimensions de l'espace cible, et la qualité de la représentation, est mesurée par le rapport de la somme de l'inertie du sous-espace de dimension réduite sur l'inertie totale. En fait, MDS métrique est équivalent à une ACP où les objets de l'analyse MDS seraient les individus de l'ACP. Dans l'exemple ci-contre, les villes seraient les individus de l'ACP et le positionnement GPS remplacerait les distances inter-villes. Mais l'Analyse MDS prolonge l'ACP, puisqu'elle peut utiliser des fonctions de similarité/dissimilarité moins contraignantes que les distances.

Avec le positionnement multidimensionnel, visualiser les matrices de dissimilarités, analyser des [benchmarks](#) et effectuer visuellement des partitionnements dans des matrices de données ou de dissimilarités sont des opérations aisées à effectuer.

### **Analyse Factorielle Multiple**

---

L'analyse factorielle multiple (AFM) est dédiée aux tableaux dans lesquels un ensemble d'individus est décrit par plusieurs groupes de variables, que ces variables soient quantitatives, qualitatives ou mixtes. Cette méthode est moins connue que les précédentes mais son très grand potentiel d'application justifie une mention particulière.

### **Exemples d'application**

---

- Dans les enquêtes d'opinion, les questionnaires sont toujours structurés en thèmes. On peut vouloir analyser plusieurs thèmes simultanément.
- Pour une catégorie de produits alimentaires, on dispose, sur différents aspects des produits, de notes données par des experts et de notes données par des consommateurs. On peut vouloir analyser simultanément les données des experts et les données des consommateurs.
- Pour un ensemble de milieux naturels, on dispose de données biologiques (abondance d'un certain nombre d'espèces) et de données environnementales (caractéristiques du sol, du relief, etc.). On peut vouloir analyser simultanément ces deux types de données.
- Pour un ensemble de magasins, on dispose du chiffre d'affaires par produit à différentes dates. Chaque date constitue un groupe de variables. On peut vouloir étudier ces dates simultanément.

### **Intérêt**

---

Dans tous ces exemples, il est utile de prendre en compte, dans l'analyse elle-même et non seulement lors de l'interprétation, la structure des variables en groupes. C'est ce que fait l'AFM qui :


- pondère les variables de façon à équilibrer l'influence des différents groupes, ce qui est particulièrement précieux lorsque l'on est en présence de groupes quantitatifs et de groupes qualitatifs ;

- fournit des résultats classiques des analyses factorielle : représentation des individus, des variables quantitatives et des modalités des variables qualitatives ;
- fournit des résultats spécifiques de la structure en groupe : représentation des groupes eux-mêmes (un point = un groupe), des individus vus par chacun des groupes (un individu = autant de points que de groupes), des facteurs des analyses séparées des groupes (ACP ou ACM selon la nature des groupes).

## Autres méthodes

Ces méthodes, mises au point plus récemment, sont moins bien connues que les précédentes.

- L'Analyse Factorielle Multiple Hiérarchique (*Hierarchical Multiple Factorial Analysis*) prend en compte une hiérarchie sur les variables et non seulement une partition comme le fait l'AFM
- L'[Analyse Procustéenne Généralisée](#) (*Generalized Procrustean Analysis*) juxtapose au mieux plusieurs représentations d'un même nuage de points.
- L'Analyse Factorielle Multiple Duale (*Dual Multiple Factor Analysis*) prend en compte une partition des individus.
- L'[Analyse Factorielle de Données Mixtes](#) (*Factor Analysis of Mixed Data*)<sup>i.41</sup> est adaptée aux tableaux dans lesquels figurent à la fois des variables quantitatives et qualitatives.



Iconographie des corrélations entre les variables des planètes. Traits pleins : corrélations positives "remarquables". Traits pointillés : corrélations négatives "remarquables".

- L'[iconographie des corrélations](#) représente les corrélations entre variables (qualitatives et quantitatives) ainsi que les individus « remarquables ». Cette méthode non supervisée se prête bien à la restitution d'une organisation, qu'elle soit arborescente ou bouclée, hiérarchique ou non. Quelle que soit la dimension des données, variables et individus remarquables

sont à la surface d'une sphère ; il n'est donc pas besoin d'interpréter des axes. Plus que sur la position des points, l'interprétation repose essentiellement sur l'organisation des liens.

- L'[ACI](#) décompose une variable multivariée en composantes linéairement et statistiquement indépendantes.
- L'[algorithme t-SNE](#) permet la visualisation des données dans un espace de deux ou trois dimensions en rendant compte des proximités locales.

## Analyse par classification

La classification des individus est le domaine de la classification automatique et de l'analyse discriminante. Classifier consiste à définir des classes, classer est l'opération permettant de mettre un objet dans une classe définie au préalable. La classification automatique est ce qu'on appelle en [exploration de données](#) (*data mining*) la classification non supervisée, l'analyse discriminante fait partie des techniques statistiques connues en exploration de données sous le nom de classification supervisée.

### Classification automatique

: [Classification automatique](#).

Le but de la classification automatique est de découper l'ensemble des données étudiées en un ou plusieurs sous-ensembles nommés classes, chaque sous-ensemble devant être le plus homogène possible. Les membres d'une classe ressemblent plus aux autres membres de la même classe qu'aux membres d'une autre classe. Deux types de classification peuvent être relevés : d'une part la classification (partitionnement ou recouvrement) « à plat » et d'autre part le partitionnement hiérarchique. Dans les deux cas, classifier revient à choisir une mesure de la similarité/dissimilarité, un critère d'homogénéité, un algorithme, et parfois un nombre de classes composant la partition.

### Classification « à plat »




fig.11 - Classification utilisant l'algorithme k-means sur les deux premières variables effectuée sur les données nutriments mises à disposition par l'université de Cologne d'après le guide de Vincent Zoonekynd sur le site « Statistics with R »




fig.12 - Classification utilisant l'algorithme PAM après une Analyse en composantes principales effectuée sur les données nutriments mises à disposition par l'université de Cologne d'après le guide de Vincent Zoonekynd sur le site « Statistics with R »

La ressemblance (similarité/dissimilarité) des individus est mesurée par un indice de similarité, un indice de dissimilarité ou une distance. Par exemple, pour des données binaires l'utilisation des indices de similarité tels que l'[indice de Jaccard](#), l'indice de Dice, l'indice de concordance ou celui de [Tanimoto](#) est fréquente. Pour des données quantitatives, la [distance euclidienne](#) est la plus appropriée, mais la [distance de Mahalanobis](#) est parfois adoptée. Les données sont soit des matrices de p variables qualitatives ou quantitatives mesurées sur n individus, soit directement des données de distances ou des données de dissimilarité.

Le critère d'homogénéité des classes est en général exprimé par la diagonale d'une matrice de variances-covariances (l'inertie) interclasses ou intra-classes. Ce critère permet de faire converger les algorithmes de ré-allocation dynamiques qui minimisent l'inertie intra-classe ou qui maximisent l'inertie inter-classes.

Les principaux algorithmes utilisent la ré-allocation dynamique en appliquant la méthode de B.W. Forgys des [centres mobiles](#), ou une de ses variantes : la méthode des [k-means](#), la [méthode des nuées dynamiques](#)<sup>b 40</sup>, ou PAM<sup>i 46</sup> (*Partitioning Around Medoids (PAM)*).

Les méthodes basées sur la [méthode de Condorcet](#), l'[algorithme espérance-maximisation](#), les densités sont aussi utilisées pour bâtir une classification<sup>i 47,i 48</sup>.

Il n'y a pas de classification meilleure que les autres, en particulier lorsque le nombre de classes de la partition n'est pas prédéterminé. Il faut donc mesurer la qualité de la classification et faire des compromis. La qualité de la classification peut se mesurer à l'aide de

l'indice qui est le rapport de l'inertie inter classe sur l'inertie totale, calculé pour plusieurs valeurs du nombre de classe total, le compromis étant obtenu par la méthode du coude.

L'interprétation des classes, permettant de comprendre la partition, peut s'effectuer en analysant les individus qui composent chaque classe. Le statisticien peut compter les individus dans chaque classe, calculer le diamètre des classes - ie la distance maximum entre individus de chaque classe. Il peut identifier les individus proches du centre de gravité, établir la séparation entre deux classes - opération consistant à mesurer la distance minimum entre deux membres de ces classes. Il peut analyser aussi les variables, en calculant par exemple la fréquence de certaines valeurs de variables prises par les individus de chaque classe, ou en caractérisant les classes par certaines valeurs de variables prises par les individus de chaque classe.

## Classification hiérarchique

### Regroupement hiérarchique.




fig.14 - Représentation 3D d'un arbre hiérarchique définissant une classification (cluster) effectuée après une analyse factorielle des correspondances multiples sur le dataset « tea » disponible sous R avec FactoMineR




fig.13 - Carte factorielle où les individus sont coloriés en fonction de leur appartenance à une classe. Ceci a été effectué par une CAH après une analyse factorielle des correspondances multiples sur le dataset « tea » disponible sous R avec FactoMineR

Les données en entrée d'une classification ascendante hiérarchique (CAH) sont présentées sous la forme d'un tableau de dissimilarités ou un tableau de [distances](#) entre individus.

Il a fallu au préalable choisir une distance (euclidienne, Manhattan, Tchebychev ou autre) ou un indice de similarité (Jacard, Sokal, Sorensen, coefficient de corrélation linéaire, ou autre).

La classification ascendante se propose de classer les individus à l'aide d'un algorithme itératif. À chaque étape, l'algorithme produit une [partition](#) en agrégeant deux classes de la partition obtenue à l'étape précédente.

Le critère permettant de choisir les deux classes dépend de la méthode d'agrégation. La plus utilisée est la [méthode de Ward](#) qui consiste à agréger les deux classes qui font baisser le moins l'inertie interclasse. D'autres indices d'agrégation existent comme celui du saut minimum (*single linkage*) où sont agrégées deux partitions pour lesquelles deux éléments - le premier appartenant à la première classe, le second à la seconde - sont le plus proches selon la distance prédéfinie, ou bien celui du diamètre (*complete linkage*) pour lequel les deux classes à agréger sont celles qui possèdent le couple d'éléments le plus éloigné.

L'algorithme ascendant se termine lorsqu'il ne reste qu'une seule classe.

La qualité de la classification est mesurée par le rapport inertie inter-classe sur inertie totale.

Des stratégies mixtes, alliant une classification « à plat » à une classification hiérarchique, offrent quelques avantages. Effectuer une CAH sur des classes homogènes obtenues par une classification par ré-allocation dynamique permet de traiter les gros tableaux de plusieurs milliers d'individus, ce qui n'est pas possible par une CAH seule. Effectuer une CAH après un échantillonnage et une analyse factorielle permet d'obtenir des classes homogènes par rapport à l'échantillonnage.

## Analyse factorielle discriminante

### Analyse discriminante.




fig.16 - AFD sur Analyse en composantes principales des données iris




fig.15 - Matrice de Nuages de points sur les données Iris présentés sur les axes des variables 2 à 2

L'analyse factorielle discriminante (AFD), qui est la partie descriptive de l'analyse discriminante, est aussi connue sous le nom d'analyse linéaire discriminante, d'analyse discriminante de [Fisher](#) et d'analyse canonique discriminante. Cette technique projette des classes prédéfinies sur des plans factoriels discriminant le plus possible. Le tableau de données décrit  $n$  individus sur lesquels  $p$  variables quantitatives et une variable qualitative à  $q$  modalités ont été mesurées. La variable qualitative permet de définir les  $q$  classes et le regroupement des individus dans ces classes. L'AFD se propose de trouver  $q-1$  variables, appelées variables discriminantes, dont les axes séparent le plus les projections des  $q$  classes qui découpent le nuage de points.

Comme dans toutes les analyses factorielles descriptives, aucune hypothèse statistique n'est faite au préalable ; ce n'est que dans la partie prédictive de l'analyse discriminante que des hypothèses *a priori* sont émises.

La mesure de la qualité de la discrimination est effectuée à l'aide du [de Wilks](#) qui est égal au rapport du [déterminant](#) de la [matrice de variances-covariances](#) intra-classe sur le

déterminant de la matrice de variances-covariances totale. Un [de Wilks](#) faible indique une discrimination forte par les plans factoriels. Par exemple sur les données Iris, il est de 0.0234 sur les deux premiers facteurs. En outre si la première valeur propre est proche de 1, l'AFD est de qualité.

La corrélation entre les variables et les facteurs permet d'interpréter ceux-ci.

Une AFD est une ACP effectuée sur les barycentres des classes d'individus constituées à l'aide des modalités de la variable qualitative. C'est aussi une analyse canonique entre le groupe des variables quantitatives et celui constitué du tableau disjonctif de la variable qualitative.